项目报告：基于 ResNet18 和语音交互的物体识别 Demo

> 版本：**v1.0.0 最终交付**。静态阈值 `0.8124` 是在**课程 5 物体样本**上、用未参与录入的测试图校准得到的**参考值**，写入特征库；`data/realtime.json` 中的 `threshold_realtime`（0.75）、`threshold_bg`（0.90）、`bg_crop_margin`（0.05）**未在标准流程下校准**，是占位值，不作为结论。

> 本报告的离线数值（10/10、6/6、178 passed 等）来自课程样本复跑，命令见各节；实机结论按小组电脑上实际演示的口述如实记录（见 §5），不补数字、不编次数。交付包默认空库，现场录入后可用 `samples/` 样本复现。

1. 系统功能

本 Demo 在**单台电脑、完全本地**完成选题书要求的全部必做项，另附一个加分项：

必做项	实现方式	状态与证据
多图录入并保存特征（带物体名称）	Tab1 录入 → 512 维特征写入 `features.json`	✅ 已实现；课程样本 5 物体 × 5 张 = 25 条向量（§3.1）
输入图片返回最相似名称与相似度	余弦相似度物体级 top-1 检索	✅ 已实现；10 张测试图 Top-1 = 10/10（§3.2）
相似度低判未知物体	最高相似度 `< 0.8124` 判未知	✅ 已实现并校准；未知 6/6 拒识、误报 0%（§3.4）
语音说出物体名称	百度短语音识别极速版 → Tab1 / Tab3 回填名称	✅ 已接线（录音 → 16k 单声道 → 识别 → 回填；未配 Key 时按钮置灰、键盘兜底）
语音播报识别结果	Edge TTS → Tab2 / Tab3 自动播放	✅ 已实现（每次播当次结果；实时链路结果变化 + 4 s 冷却；失败降级提示）
简单界面完成录入/识别/查看	Gradio Tab1 录入 / Tab2 识别 / Tab3 实时+教学	✅ 已实现
重启后特征库仍在	JSON 原子写入 + 启动时加载	✅ 已实现（`save_library` 原子替换、`load_library` 启动读取）

加分项：摄像头实时识别（Tab3）+ 教学式录入。摄像头实时页已在小组电脑上实机测试，但存在手部干扰这一已知局限（见 §5.2）。

2. 实现方法

2.1 总体架构

双链路共用同一个核心层 `core/`，界面层（`app.py`）与语音层（`voice/asr.py`、`voice/tts.py`）都只调用核心层函数，互不耦合。实时链路与静态链路共用 `core/pipeline.py` 的 `recognize_static` / `recognize_stream`，没有第二套特征或检索逻辑。

```
flowchart LR
    A[图片] --> B[core.features 提取 512 维 + L2 归一化]
    B --> C[core.library 写入 features.json]
    B --> D[core.recognize 余弦检索 + 判未知]
    D --> E[Tab2 识别结果 / 标注图]
    D --> F[core.pipeline recognize_stream 实时链路]
    G[麦克风/音频] --> H[voice.asr 百度识别]
```

```
    H --> I[录入物体名 / 教学态名称]
    D --> J[voice.tts Edge TTS 播报]
```

2.2 关键技术决策

- **去掉 ResNet18 的 `fc` 层**：ImageNet 的 1000 类分类头对自定义物体无意义；去掉后输出 512 维池化特征，可直接做"以图搜图"式检索。

- **L2 归一化**：归一化后余弦相似度退化为点积，检索是一次 `(N,512) @ (512,)` 矩阵乘法；向量模长不再影响阈值，阈值可跨图片复用。

- **复用 `weights.transforms()`**：与权重训练时一致的预处理，避免手写预处理导致特征分布偏移。

- **按物体取最大相似度**：多视角注册时"只要有一张注册图很像就认为该物体很像"，对多视角录入更友好（代价是注册图要真实清晰、无重复）。

- **JSON 特征库而非数据库**：满足"重启后特征库仍在"，零依赖、可读、约 300 KB；用 SQLite / FAISS 属工程化扩张，不加分。

- **阈值三级优先级**：显式参数 > 特征库 `threshold`（课程样本校准的参考值 `0.8124`）> 代码兜底 `DEFAULT_THRESHOLD`（见 `core/recognize.py`）。兜底值只在"库未经校准"时生效，**不是最终结论**，也不写进测试结论。

- **密钥不写死**：只从环境变量或 `.env` 读取，repr 屏蔽 Secret，异常只带错误码不拼接含 Secret 的 URL。

2.3 实时背景自适应（P5.1）

目标：摄像头前的环境复杂，整帧特征容易被背景主导，出现"背景被认成已录入物体"或"物体在场却认不出"。实现仍走 ResNet18 + 余弦检索，不引入检测/分割模型，也不接在线服务。

```
flowchart LR
    A[实时帧] --> B[512 维特征]
    B --> C{cos(帧, BG) > T_bg?}
    C -->|是| D[画面中没有可识别物体<br/>不检索 / 不播报]
    C -->|否| E[全帧检索 + 中心 60% 裁剪检索]
    E --> F{裁剪分 - 全帧分 > bg_crop_margin?}
    F -->|是| G[采用裁剪结果 source=crop]
    F -->|否| H[采用全帧结果 source=full]
    G --> I[用 T_rt 判未知 + 标注 + 播报]
    H --> I
```

- **背景学习**：进实时页先收 20 帧，丢前 2 帧（黑帧/过曝），对剩余 18 帧逐维取中位数并 L2 归一化；写入独立的 `data/background.json`，schema 为 `rn18-background`。丢弃预热帧后不足 10 帧直接报错。背景不写入 `features.json`，不计入物体数量，不进入 P6b 校准集。Gradio 4.44 没有 tab 切换事件，学习由实时页的**第一帧**触发；没开摄像头/没播放帧序列时不会空转。

- **背景门**：每帧先算与背景向量的余弦，`bg_sim > T_bg` 时返回 `state="no_object"`，不检索、不产生播报文本；界面统计行显示「背景已建立」与 T_rt/T_bg。可点「重新学背景」重来，也可关掉背景门回到未启用背景门时的单路行为做对照。

- **中心裁剪第二路**：PIL 裁 `0.2~0.8` 的中心 60%，只有「裁剪分 - 全帧分 > `bg_crop_margin`」才采用，`StreamResult.source` 标记 `full`/`crop`。

- **阈值分离**：`threshold_static`（库里的 0.8124，不动）、`threshold_realtime`（占位 0.75）、`threshold_bg`（占位 0.90）、`bg_crop_margin`（占位 0.05）、`bg_gate_enabled` 写在 `data/realtime.json`。**T_rt/T_bg/margin 未在标准流程下校准**，三项都标「占位/未验证」，不由代码编造结论；**没有把 0.8124 直接用于实时链路**。

- **自检工具**：`tools/realtime_check.py` 支持 `--frames`（离线、不依赖 opencv）与 `--camera`（opencv 可选依赖），输出背景相似度基线（min/median/max）、空场景 30 帧最大误报分/次数、物体分数分布与阈值建议；`--write` 只写 `realtime.json`。两分布重叠时脚本拒绝给数字，避免把拍脑袋的值写进配置。

3. 测试结果

> **口径说明**：本节的 10/10、6/6、178 passed 等结果，均基于课程 **25 条注册图样本**（5 物体 × 5 张）复跑得到；样本随交付包放在 `samples/`，**仅用于报告复现，不自动入库**。**交付包默认空库**（`data/features.json` 的 `objects` 为空、不含任何向量），现场手动录入后可用 `samples/` 复现这些数字。表里的 `data/known/...`、`data/test/...` 为采集时的相对路径，对应本包 `samples/known/...`、`samples/test/...`；下面的复现命令请用 `samples/` 下的目录。

3.1 数据集说明（口径）

用途	物体数	每物体张数	合计	是否入库
注册图 `data/known/<物体>/`	5	5	25	入库（25 条向量）
测试图 `data/test/<物体>/`	5	2	10	不入库，仅评测
未知样本 `data/unknown/<物体>/`	3	2	6	不入库，仅校准
合计	—	—	**41**	—

- 5 个已知物体：`power_bank`、`water_cup`、`earphone`、`keyboard`、`mouse`。

- 3 个未录入物体：乌龙茶、充电头、剪刀。

- `data/manifest.csv` 是**唯一入库清单**：known 25 行 + test 10 行，按**文件字节 SHA-256**去重，摘要全不相同（CSV 第 4 列列名沿用 `md5`，实际值为 SHA-256）。

- 未知样本 6 张与 known（25）、test（10）逐字节比对 **md5 零重叠**；known 与 test 之间同样零重叠。**校准集不含任何注册图**。

- 注册图与测试图拍摄角度/距离不同，测试图未参与录入。

3.2 已知物体检索（Top-1）

用真实特征库（25 条）复跑 10 张未参与录入的测试图：

测试图	真实物体	预测	相似度	≥ 阈值 0.8124	正确
data/test/earphone/01.jpg	earphone	earphone	0.9610	是	是
data/test/earphone/02.jpg	earphone	earphone	0.9219	是	是
data/test/keyboard/01.jpg	keyboard	keyboard	0.9050	是	是
data/test/keyboard/02.jpg	keyboard	keyboard	0.9237	是	是
data/test/mouse/01.jpg	mouse	mouse	0.9568	是	是
data/test/mouse/02.jpg	mouse	mouse	0.9734	是	是
data/test/power_bank/01.jpg	power_bank	power_bank	0.8828	是	是
data/test/power_bank/02.jpg	power_bank	power_bank	0.9239	是	是
data/test/water_cup/01.jpg	water_cup	water_cup	0.9392	是	是
data/test/water_cup/02.jpg	water_cup	water_cup	0.9026	是	是

- **Top-1：10/10，准确率 100%**

- **平均余弦 0.9290**；最低 0.8828（power_bank/01），最高 0.9734（mouse/02）

- 最低分高于阈值 0.8124 有 **0.0704** 余量，说明已知类没有被阈值误杀

- 复现：`python tools/demo_cli.py eval --dir samples/test --json`

3.3 阈值校准：两条分布（`tools/calibrate.py` 真实输出）

```
python tools/calibrate.py --known-dir samples/test --unknown-dir samples/unknown
特征库: .../features.json
当前（占位/已校准）阈值: 0.8124

[已知类] 测试图 10 张
  最高相似度  min=0.8828  max=0.9734  mean=0.9290
    earphone    n=2   min=0.9219 max=0.9610
    keyboard    n=2   min=0.9050 max=0.9237
    mouse       n=2   min=0.9568 max=0.9734
    power_bank n=2   min=0.8828 max=0.9239
    water_cup   n=2   min=0.9026 max=0.9392

[未知类] 样本 6 张
  最高相似度  min=0.6282  max=0.7421  mean=0.6897

建议阈值（已知 min 与未知 max 中点）: 0.8124
→ 用 `python tools/demo_cli.py threshold --set <值>` 写回特征库。
```

分布	样本数	min	max	mean
已知类（test 10 张）	10	0.8828	0.9734	0.9290
未知类（unknown 6 张）	6	0.6282	0.7421	0.6897

阈值取法：已知类最小值 0.8828 与未知类最大值 0.7421 之间的分离间隙为 **0.1407**，取中点为 `(0.8828 + 0.7421) / 2 = 0.8124`，两侧余量各约 **0.070**（已知侧 0.0704，未知侧 0.0703）。

为什么不用其他取法：

- 取更低的点（贴近未知最大值）会放大误报风险，而未知样本只有 6 张，样本偏差会让边界不稳；

- 取更高的点（贴近已知最小值）会牺牲召回，且 power_bank/01 的 0.8828 是已知侧离群低点，再往上顶会先杀掉它；

- 中点法在两侧间隔近似对称时使两类错误概率最均衡，也是 `calibrate.py` 的可复现输出，便于答辩时解释来源。

写入配置：

```
python tools/demo_cli.py threshold --set 0.8124
# {"threshold": 0.8124, "saved": true}
```

3.4 未知样本拒识验证（阈值写入后复跑）

未知图	真实物体	库里最近物体	最高分	判定	结果
乌龙茶1.jpg	乌龙茶	water_cup	0.6893	未知物体	✅ 正确拒识
乌龙茶2.jpg	乌龙茶	water_cup	0.7059	未知物体	✅ 正确拒识
充电头1.jpg	充电头	power_bank	0.7421	未知物体	✅ 正确拒识
充电头2.jpg	充电头	earphone	0.7362	未知物体	✅ 正确拒识
剪刀1.jpg	剪刀	mouse	0.6366	未知物体	✅ 正确拒识
剪刀2.jpg	剪刀	mouse	0.6282	未知物体	✅ 正确拒识

- **未知拒识率 6/6 = 100%，误报率 0/6 = 0%**

- 最高分样本：充电头1.jpg，0.7421，距阈值 -0.0703

- 复现：`python tools/unknown_check.py --dir samples/unknown`（全正确拒识时退出码 0，出现误报返回 1）；原始输出见 `docs/evidence/p6b_verification.txt`，校准输出见 `docs/evidence/p6b_calibration.txt`

外形相近物体的专项说明（充电头 vs 已录入的充电宝）：

充电头是本次最接近已知类的未知物体，两张分别被判为 `power_bank`（0.7421，库里最近图 `power_bank/03.jpg`）与 `earphone`（0.7362）。它确实是未知样本里的最高分，但**离已知类最低分 0.8828 仍有 0.1407 的差距**，因此**没有把阈值逼高**：若为它上抬阈值，就得超过 0.8828，直接牺牲 power_bank/01 这张已知测试图的召回（0.8828 会掉到阈值下）。取 0.8124 时两侧各留 0.070，兼顾了"充电头判未知"和"充电宝判已知"。

两张充电头分属不同最近邻（一张像充电宝、一张像耳机），说明它的高分并非稳定地贴着某一个已知物，而是"整体都沾一点"，这正是外观相近但材质/结构不同的表现，也说明只用单张注册图做阈值会不稳——现有 5 张多视角注册压住了这个风险。

> 局限：未知样本仅 3 类各 2 张，样本量小。0.8124 是课程样本上的参考值，分离间隙虽然宽（0.1407），但离群样本出现时阈值可能需微调；现场若录入与课程样本差异较大的物体，建议用 `tools/calibrate.py` 重新校准。

3.5 单元与端到端测试

```
python -m pytest tests -q                    # 178 passed, 4 skipped（P5.1 实现后）
RUN_RESNET_TESTS=1 python -m pytest tests -q  # 含真实权重端到端
```

- 环境：Python 3.11.9（`setup_env.bat` 在 `.venv` 中实跑）/ torch 2.2.2+cpu / torchvision 0.17.2+cpu / numpy 1.26.4 / gradio 4.44.1。应用依赖在 `requirements.txt` 中全部钉死版本（含 5 个传递依赖），与 README 「环境安装」锁定表一致。真实权重端到端用例默认跳过，未在本机联网下载权重。

- 默认运行跳过 4 项：3 项真实 ResNet 端到端用例（需 `RUN_RESNET_TESTS=1`）、1 项真实 Edge TTS 联网用例（需 `RN18_TTS_LIVE=1`）。

- 新增覆盖：`test_background.py`（20 帧丢 2 帧中位数、10 帧下限、余弦边界、save/load 校验、与特征库分离）、`test_bg_gate.py`（门命中检索/TTS 调用 0 次、裁剪 margin、门关等价、T_rt 不套静态阈值）、`test_pipeline.py` / `test_realtime.py` / `test_realtime_check.py` 适配新接口。

3.6 边界与降级

- **未配置百度 Key**：`voice.asr.is_asr_configured()` 返回 `False`，界面启动时「语音识别名称」按钮 `interactive=False`，点击只提示"未配置语音识别密钥，请用键盘输入"，**不调用 `asr`**；命令行直接调用 `asr()` 则抛 `AsrNotConfigured`（可捕获的预期状态，不是崩溃）。键盘录入与文本结果显示照常。

- **语音播报**：网络/依赖失败时界面显示「语音播报不可用，请检查网络」，识别结果与特征库不受影响。实时链路按「结果变化 + 4 s 冷却」节流，教学态同时暂停识别与 TTS，退出时清空冷却。

- **空特征库**：识别时返回"未知物体"并提示先录入，不抛未捕获异常。交付包默认就是空库。

- **特征库损坏**：加载失败抛 `ValueError`，不静默覆盖磁盘文件。

- **阈值未校准**：库里没有 `threshold` 时回落到代码兜底值并可用 `--threshold` 临时覆盖；该兜底值不是本项目的结论，报告结论不采用它。

3.7 P5.1 背景自适应：离线自测与真机待校准项

单元/集成测试（本机实跑）：

```
178 passed, 4 skipped, 12 warnings in 19.31s
```

当前阈值与状态（全部写在 `data/realtime.json`）：

键	当前值	状态
`threshold_static`	0.8124	课程样本上校准的参考值，写进特征库，**不动**
`threshold_realtime`	0.75	**未在标准流程下校准**的保守占位；不是 0.8124，也不是实时结论
`threshold_bg`	0.90	**未在标准流程下校准**的保守占位
`bg_crop_margin`	0.05	**未在标准流程下校准**的裁剪采用 margin
`bg_gate_enabled`	true	背景门开关；false 时回到未启用背景门时的单路行为，便于对照

没有做的事（避免把占位值写成结论）：`tools/realtime_check.py` 的真机阈值校准尚未在标准流程下执行，因此没有伪造"空场景 30 秒无误报""物体 1 秒内识别""移走 1–2 秒恢复"这类数据。`realtime_check.py --camera 0 --seconds 30` 仍需在小组电脑上实跑，再把建议值人工确认后写回 `data/realtime.json`；在此之前，报告与口头汇报不声称实时阈值已校准。摄像头实时页本身已在小组电脑上实机测试（见 §5），这与"实时阈值未校准"是两件事。

P5.1 验证清单（离线部分已过，真机部分待做）：

验证点	方式	状态
收集 20 帧、丢前 2 帧、逐维中位数、L2 归一化	`test_background.py` 512 维假编码器手算	✅
丢弃预热帧后不足 10 帧报错	`test_background.py`	✅
余弦边界 1 / 0 / -1，严格 `>` 判背景	`test_background.py`	✅

`save` → `load` 往返；非 512 维/未归一化拒绝	`test_background.py`	✅
背景文件与 `features.json` 分离、库哈希不变	`test_background.py`	✅
背景门命中不检索、不生成播报文本	`test_bg_gate.py` 打桩断言调用 0 次	✅
裁剪差值 ≤ margin 用 full，> margin 用 crop	`test_bg_gate.py`	✅
`bg_gate_enabled=False` 与未启用背景门时逐帧等价	`test_bg_gate.py` 比较 `recognition` 与标注字节	✅
实时链路使用 T_rt，不套 0.8124	`test_bg_gate.py` / `test_pipeline.py`	✅
自检脚本离线模式可跑、只写 `realtime.json`	`test_realtime_check.py`	✅
空场景 30 s 无误报、物体 1 s 内识别、移走 1–2 s 恢复	**真机摄像头**	未验证/占位

4. 成员分工

> 按选题书末尾的小组信息表填写，全部用「待填」占位，由小组定稿时填写。

项目	内容	主要分工
小组名称	待填	—
负责人	待填	—
选择题目	☑ 选题一 物体识别	—
成员一	待填	待填
成员二	待填	待填
成员三	待填	待填
成员四	待填	待填
成员五	待填	待填

单人组队时，成员二～五可写「一人承担全部模块」。开发过程中使用大模型辅助查询与参考代码，关键模块由本人复核并说明。

5. 实机结论与未验证项

本章按小组电脑上实际演示的口述如实记录：§5.1 是实机确认项，§5.3 是尚未实测、照实保留「未验证/占位」的项。不补数字、不编次数，也不伪造任何实验结果、截图或开发记录。

5.1 实机确认

项目	实机结论
语音识别（百度短语音识别）	实机确认可用，真人说话回填名称正常
语音播报（Edge TTS）	实机确认可用，中文正常，播报当次识别结果
标注图	中文显示正常
摄像头实时页（加分项）	已实机测试，但存在手部干扰：手举物体时常被当成目标，属**已知局限**

5.2 摄像头手部干扰：根因与使用建议

根因：整帧 ResNet18 特征没有"目标区域"的概念，阈值只管分数高低，无法区分这一帧的贡献来自手还是物体；界面上的标注框是**整图状态框，不是目标检测框**。选题书不要求定位物体，本项目未引入检测模型，也没有实现手部剔除。

使用建议（演示时用来减轻干扰，不是已实现的功能）：

- 把物体居中、尽量占满画面；
- 手退出画面后再判定；
- 等连续多帧结果稳定后再采信。

5.3 未验证 / 占位

项目	状态
`tools/realtime_check.py` 真机阈值校准（`T_rt` / `T_bg` / `bg_crop_margin`）	未验证/占位：0.75 / 0.90 / 0.05 仍未在标准流程下校准
权重离线现场首跑（`resnet18-f37072fd.pth` 已在演示机缓存目录、首跑不联网）	未验证/占位
现场四项演示的连贯走通（多图录入 / 识别 / 未知判断 / 语音交互 同场一次走完）	未验证/占位
复杂背景下的表现	未验证/占位